



The Bias Mirror

WORKSHOP

Un laboratorio di Hacking Linguistico ed Educazione Digitale per scoprire cosa si nasconde davvero dietro le parole dell'Intelligenza Artificiale. Tre ore per smontare, analizzare e riscrivere il linguaggio delle macchine.

Durata

180 minuti — 3 ore di laboratorio attivo

Target

AI beginners

Il Percorso in Tre Atti

Il workshop si sviluppa come un viaggio progressivo: dalla scoperta inconsapevole del pregiudizio, alla sua analisi rigorosa, fino alla costruzione di strumenti concreti di difesa critica.



Parte 1: La De-costruzione

00–45 min · Icebreaker "Prompting al buio" e metafora del Pappagallo Stocastico. Scopriamo il bias senza saperlo.




Parte 2: La Sperimentazione

45–105 min · Laboratorio di "Prompt Surgery". Diventiamo linguisti investigativi e riscriviamo i prompt difettosi.



Parte 3: La Sintesi

105–180 min · Debate su AI e Società, riflessione sui lavori e stesura del "Manuale del Navigatore Critico".



ORA 1 · 00-15 MIN

Il Test del Pregiudizio Invisibile

L'icebreaker si chiama "**Prompting al buio**". Il pubblico viene diviso in gruppi, ognuno con un compito apparentemente semplice: generare su ChatGPT la bio di un personaggio descritto solo dal suo ruolo sociale.



Es. Gruppo A

"Un genio informatico che vive in un garage."



Es. Gruppo B

"Una persona che ha perso tutto e vive per strada."



Es. Gruppo C

"Un influencer di estremo successo nel settore beauty."

📋 Proiettiamo i risultati e poniamo la domanda chiave: **Quante bio descrivono un uomo? Quante una persona caucasica? Che linguaggio viene usato — aggressivo, vittimistico, patinato?**

Anatomia di un Pappagallo Stocastico

L'AI non pensa. Prevede.

Un Large Language Model non ha opinioni né coscienza. Si limita a calcolare la parola *statisticamente più probabile* da inserire dopo quella precedente. Per farlo, si basa su miliardi di esempi di testi umani. È un pappagallo molto sofisticato — non un interlocutore. Se il web degli ultimi 20 anni è saturo di stereotipi, l'AI li assorbe, li comprime e li restituisce amplificati.

La Metafora della Biblioteca Infinita

Immagina una biblioteca con ogni libro, articolo e post mai scritto. L'AI ha "letto" tutto. Ma se quella biblioteca riflette decenni di squilibri culturali, razziali e di genere, anche il lettore più veloce del mondo imparerà gli stessi pregiudizi.

Word Embeddings — È Matematica

Le parole sono punti nello spazio matematico. Se "Donna" è geometricamente più vicina a "Famiglia" che a "Carriera", l'AI farà fatica a immaginare scenari diversi. **Non è un'opinione. È algebra.**

Le Parole come Punti nello Spazio

*Il concetto di **Word Embedding** è il cuore della spiegazione scientifica del bias. Ogni parola viene trasformata in un vettore numerico — una coordinata in uno spazio multidimensionale. La vicinanza tra vettori determina le associazioni semantiche dell'AI.*

300+

I modelli moderni rappresentano ogni parola in centinaia di dimensioni matematiche.

~1T

Token di Training

GPT-4 è stato addestrato su circa un trilione di token — ogni token è circa una parola.

20+

I corpora includono testi degli ultimi vent'anni del web, con tutti i loro pregiudizi sedimentati.

Il risultato? **Uomo: Programmatore = Donna: Receptionist.** Un paradigma emerso realmente dagli studi sui modelli linguistici. Non una scelta deliberata — un riflesso statistico della società che li ha creati.

Laboratorio: Linguisti Investigativi

*I gruppi ricevono un "**Output Difettoso**" — un testo generato in precedenza e palesemente inficiato da bias. La missione è analizzarlo come detective del linguaggio, usando un sistema di codifica cromatica precisa.*



 **Rosso**

Sottolinea gli **stereotipi di genere ed etnia**: ogni assunzione implicita sull'identità del soggetto.



 **Blu**

Evidenzia le **scelte lessicali squilibrate**: parole che sminuiscono o esaltano ingiustamente il soggetto.



 **Verde**

Marca le **omissioni narrative**: cosa il testo non dice? Quale prospettiva è stata silenziata?

 **Analisi Etimologica**: Come cambia la percezione usando "ambizioso" invece di "arrampicatore"? Due parole con lo stesso referente, ma connotazioni opposte. **Il linguaggio non è neutro — è sempre una scelta.**

Prompt Surgery: Tre Tecniche di De-biasing

Dopo aver identificato il problema, è il momento di operare. I gruppi riscrivono i prompt originali applicando tre tecniche chirurgiche per ridurre o eliminare il bias nei risultati dell'AI.



1. Neutralizzazione

Rimuovere qualsiasi riferimento che possa attivare stereotipi automatici. Eliminare genere, etnia, età e classe sociale quando non rilevanti per il contenuto richiesto.



2. Counter-Priming

Inserire nel prompt elementi di rottura espliciti. Esempio: *"Descrivi un infermiere uomo sottolineando la sua forza fisica e la sua estrema empatia"* — si forzano associazioni inusuali per scardinare gli automatismi.



3. Specificità Lessicale

Sostituire aggettivi vaghi con descrizioni d'azione concrete. "È una persona dolce" diventa "gestisce conflitti con calma e ascolto attivo". I verbi descrivono comportamenti; gli aggettivi proiettano giudizi.

ORA 3 · 105-145 MIN

Il Debate: AI & Società nel 2030

***Scenario di gioco:** Siamo nel 2030. Un'AI decide chi riceve un prestito bancario e chi viene ammesso a un'università d'élite. Il modello è addestrato sui dati storici degli ultimi 50 anni.*

La Domanda Centrale

Se i dati storici riflettono decenni di discriminazione sistemica, l'AI sarà ingiusta **per definizione matematica**. È possibile costruire un sistema equo su fondamenta ineque?

Correggere i Modelli

Basta "pulire" i dati di addestramento? O serve una **supervisione umana costante** — il principio del Human-in-the-loop — per ogni decisione ad alto impatto sociale?

Chi Decide Chi Decide?

Chi sceglie i criteri di "pulizia" dei dati? Chi definisce cos'è giusto? Il design dell'AI è sempre una **scelta sociale e culturale**, non solo tecnica.

Il Manuale del Navigatore Critico

*Ogni gruppo presenta il prompt "curato", mostrando come l'output dell'AI è cambiato. La restituzione finale è il **Manuale del Navigatore Critico** — un kit di autodifesa algoritmico da tenere sempre con sé.*

Regola 1 — Non fidarti dell'aggettivo "di default"

Quando l'AI descrive qualcuno con aggettivi automatici (brillante, fragile, aggressivo), chiediti: questa scelta riflette la realtà o lo stereotipo più frequente nel corpus di addestramento?

Regola 2 — Interroga l'AI sulle sue fonti

Chiedi esplicitamente: "Su quali dati basi questa affermazione?" o "Questa risposta potrebbe contenere bias di genere o etnia?". L'AI spesso risponde onestamente, se interpellata direttamente.

Regola 3 — Usa il linguaggio per forzare i confini della statistica

Il prompt è uno strumento di potere. Scegliere le parole giuste, aggiungere vincoli espliciti, usare il counter-priming: sei tu il programmatore del prossimo output. Non delegare questa responsabilità.

Riflettere, Criticare, Agire

Il bias algoritmico non è un problema tecnico da risolvere in un server farm. È uno specchio della nostra cultura — e come ogni specchio, può essere rotto, distorto o, con il lavoro giusto, corretto.

Hai imparato a vedere

Il bias invisibile non è più invisibile. Ora sai dove guardare e cosa cercare nel testo generato dall'AI.

Hai imparato a operare

La Prompt Surgery ti ha dato strumenti concreti: neutralizzazione, counter-priming, specificità lessicale.

Hai imparato a resistere

Il Manuale del Navigatore Critico è il tuo kit di autodifesa per ogni interazione futura con sistemi AI.



"Il linguaggio non è uno strumento neutro. Chi lo controlla, controlla la realtà che descrive."